RAG 项目

混合检索
任务工单

八维文化与产业研究院

2025 年 1 月

八维教育
BAWAY EDUCATION

1 基本信息

工单对应的项目名称	RAG
工单编号	人工智能 NLP-RAG-混合检索任务
创建时间	2025 年 1 月 21 日
创建人	王洪荣

2 任务描述

任务描述	作为 <用户>  招股说明书1.pdf  招股说明书2.pdf 我想要 <在基于招股说明书的问答系统中，优化检索策略，

提供向量检索（召回+重排）和全文检索以及两者同时执行的混合检索的检索策略的配置及应用的功能；



1. 功能目标

优化问答系统的检索策略，提供多种检索方式的配置及应用，包括：

向量检索（召回+重排）：通过向量嵌入和相似度计算实现高效召回，并结合重排算法优化检索结果。

全文检索：支持基于关键词的全文检索，快速定位文档中的相关内容。

混合检索：同时执行向量检索和全文检索，结合两者优势，提供更准确的检索结果。

2. 功能详细需求

（1）向量检索（召回+重排）

需求描述：

使用向量嵌入技术将招股说明书内容和用户 Query 转换为向量表示。

实现高效的向量召回机制，通过相似度计算（如余弦相似度）快速检索相关文档片段。

应用重排算法（如基于 LLM 的重排器）对召回结果进行优化排序。

技术要求：

支持多种嵌入模型（如 bge、m3e 以及其他嵌入模型）。

提供至少 3 种重排算法（如基于 LLM 的重排器、基于 TF-IDF 的重排器、基于用户反馈的自适应重排器）。

（2）全文检索

需求描述：

实现基于关键词的全文检索，支持布尔查询、短语匹配和模糊匹配。

提供高效的索引机制，支持快速定位文档中的相关内容。

技术要求：

使用倒排索引技术实现全文检索。

支持多字段检索（如标题、正文、摘要）。

（3）混合检索

需求描述：

同时执行向量检索和全文检索，结合两者的优势，提供更全面的检索结果。

	提供混合检索的配置选项，允许用户根据需求调整检索策略。 技术要求： 支持向量检索和全文检索的权重调整。 提供混合检索结果的融合算法，如加权平均、投票机制等。 3. 任务目标 **准确率：优化后的检索策略应显著提升检索结果的准确率，目标准确率提升至 90%以上。** **召回率：确保重要信息的召回率，目标召回率提升至 95%以上。** > **以便于 <提升 PDF 文档的检索精度。>**
工时预估	2 人日
产出物	一、功能实现代码 二、演示 1、提供一个完整的演示视频，展示系统的功能和操作流程。 2、提供一个演示视频，讲解语义检索、全文检索分别用的检索技术，以及检索精度提升的测试问题及检索答案；
验收标准	一、功能验收 1、**准确率：优化后的检索策略应显著提升检索结果的准确率，目标准确率提升至 90%以上。**

	召回率：确保重要信息的召回率，目标召回率提升至 95%以上。 2、检索问题的答案； 3、交互友好性：提供清晰、简洁的用户界面，支持多轮对话和用户反馈。 4、多语言支持：支持中文和英文的问答。 二、性能验收 1、响应时间：从用户提问到返回答案的时间应不超过 3 秒。 2、资源消耗：系统应合理利用计算资源，确保在高并发环境下稳定运行。
备注	代码注释需包括工单编号：人工智能 NLP-RAG-混合检索任务

北京八维信息集团