RAG 项目

RAG 性能瓶颈识别与优化
任务工单

八维文化与产业研究院

2025 年 8 月

八维教育 BAWAY EDUCATION

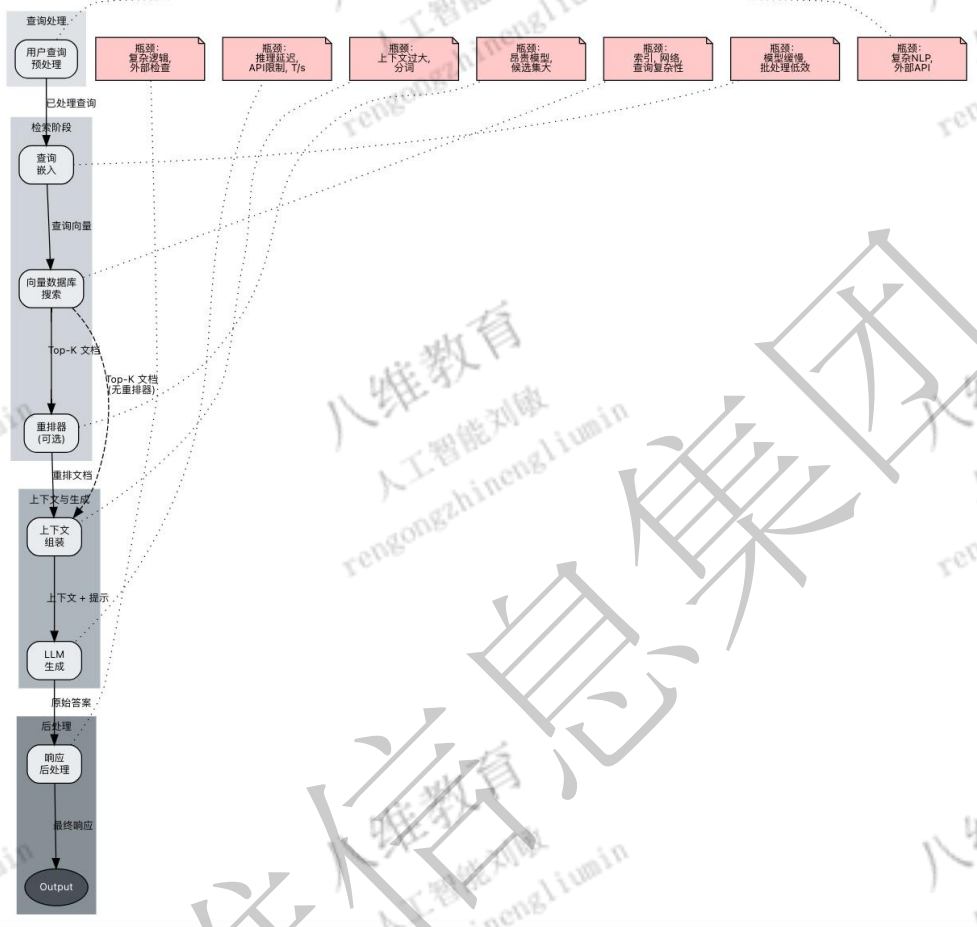
1 基本信息

工单对应的项目名称	RAG
工单编号	人工智能 NLP-RAG 项目-RAG 性能瓶颈识别与优化
创建时间	2025 年 8 月 26 日
创建人	王洪荣

2 任务描述

任务描述	RAG 系统搭建后，RAG 检索结果返回时间要优化到 3S 以内；针对检索结果返回时间过长的问题，需要分析性能瓶颈的原因。 RAG 系统的延迟是其组成部分的延迟之和，再加上各阶段之间数据传输或排队产生的任何开销。另一方面，吞吐量通常由处理能力最低的阶段决定。让我们分析典型的 RAG 流程，并审视潜在的瓶颈。

北京八维信息集团



通过分析查询处理与增强、检索阶段、上下文组装与提示工程、LLM 生成、后处理与响应格式化这几个流程的运行时间，分析出影响性能慢的原因在哪里；具体参考：

https://apxml.com/zh/courses/optimizing-rag-for-production/chapter-1-production-rag-foundations/rag-performance-bottlenecks

识别缓慢之处的工具和技术：

识别您的 RAG 系统大部分时间花在哪里需要结合使用多种工具和系统调查。

北京八维信息集团

1、性能分析：

- 应用级性能分析器：使用特定于您编程语言的工具（例如 Python 的 cProfile 和 snakeviz、Java 的 JProfiler 或 VisualVM、Go 的 pprof）。这些工具有助于确定应用程序组件中缓慢的函数和代码路径。
- 系统级性能分析器：Linux 上的 perf 等工具可以提供关于 CPU 使用、系统调用和其他内核级活动的了解，这对于诊断 I/O 瓶颈或原生代码库问题很有帮助。

2、日志记录：

- 在每个主要处理阶段和子阶段的进入和退出处，实施带有详细时间戳的结构化日志记录。
- 包含标识符（例如，请求 ID）以追踪单个请求在流程中的执行情况。
- 记录相关指标，如检索到的文档数量、上下文长度和生成的 token。分析这些日志可以显示与慢请求相关的模式。

3、分布式追踪：

对于构建为微服务集合的 RAG 系统，分布式追踪系统（例如 OpenTelemetry、Jaeger、Zipkin）是必不可少的。它们提供请求在多个服务之间传输的统一视图，从而更容易查看是哪个服务或服务间调用导致延迟。

4、监控与告警：

	设置仪表盘（使用 Grafana、Prometheus、Datadog 等工具）来可视化每个组件的重要性能指标（KPIs）： 延迟（平均值、中位数、95/99 百分位数） 吞吐量（每秒/每分钟请求数） 错误率 资源利用率（CPU、内存、GPU、网络、磁盘 I/O） 队列长度（如适用，例如 LLM 处理前的请求队列） 配置告警，以便在这些指标超过预设阈值时通知您，这表明性能下降或存在潜在瓶颈。 5、负载测试： 定期进行负载测试（例如，使用 k6、Locust、JMeter 等工具）以模拟生产流量。瓶颈通常只在压力下显现出来。 分别测试系统的不同部分，然后进行端到端测试，以理解组件在负载下的相互影响。 分析延迟和吞吐量如何随负载增加而变化。性能急剧下降的点通常表明存在瓶颈。 6、基准测试： 单独对各个组件（例如，不同的嵌入模型、向量数据库配置、LLM 推理设置）进行基准测试，以了解其原始性能特征。这有助于在系统设计和优化过程中做出明智的选择。 任务目标：分析造成检索性能慢的原因在哪里，并对应优化，

北京八维信息集团

	并给出优化前后的检索时间对比；
工时预估	1 人日
产出物	1、过程跟踪步骤，过程问题记录文档或者演示视频； 2、出现瓶颈的原因、优化方案及性能提升对比
验收标准	每个会话，用户输入 query 后，返回的检索结果要在 3S 以内；
备注	

北京八维信息集团