RAG 项目

实现文档质量评估 Skill 并集成至智能体工作流工单

八维文化与产业研究院

2026 年 1 月

八维教育 BAWAY EDUCATION

1 基本信息

工单对应的项目名称	RAG
工单编号	人工智能 NLP-RAG-实现文档质量评估 Skill 并集成至智能体工作流工单
创建时间	2026 年 1 月 23 日
创建人	王洪荣

2 任务描述

任务描述	作为最早提出 MCP 的先驱，Anthropic 的步伐并未停歇，近日又抛出了一个新的概念——Skills，并宣布于 2025 年 12 月正式将 Agent Skills 作为开放标准发布。 MCP 的本质是对“工具调用”的协议标准化。它的初衷是解决 N 个模型适配 M 个工具 带来的 的复杂度问题。 然而，MCP 仅仅定义了“手”怎么动（工具如何被调用），却没定义“脑”怎么想（业务逻辑如何编排）。 为了填补这一空白，Anthropic 推出了 Skills 的概念。 所谓 Skill（技能），字面意思即“完成某项特定任务的能力”。

如果打个比方，厨师（大模型）拥有了做菜的技能，核心在于他知道如何按照特定的工序和流程，在正确的时机调度正确的厨具来产出结果。

由此可见，SKILL 本质上是一种标准化的 SOP（标准作业程序），它是对某项任务最佳实践的沉淀。它不仅包含了任务的定义，还封装了执行流程及配套资源。

在 Skill 的架构中，这一理念体现为三层结构：

元数据层（始终加载）：技能的名称与简介（告诉模型这是什么，消耗极低 Token）。

指令层（SKILL.md，在触发时加载）：定义核心工作流程和步骤（告诉模型怎么做，中等 Token）。

资源层（按需加载）：完成技能所需的配套脚本、参考文档、模板数据（执行时才调用，Token 消耗大）。

任务一：在 Cursor/Trae 中导入和使用 Claude Skills

https://blog.csdn.net/u012141621/article/details/156949535

任务二：使用 skill-creator 创建并实现文档质量评估 Skills (DocumentQualityAssessmentSkill)

在构建特定领域的知识库前，需要对各类知识库文件进行质量

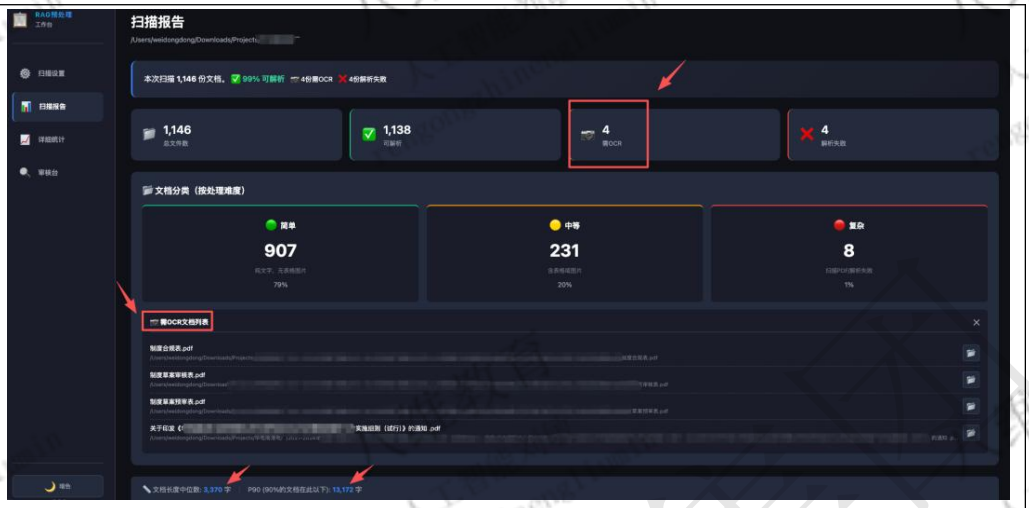
评估，请设计一款知识库文档的文档质量评估 Skills，实现如下功能：

一、**基本功能：格式分布统计、PDF 文字型/扫描型分流、文档长度分布、MD5 重复检测；**

1、**格式分布统计**：遍历文件夹，统计 .pdf, .docx, .md 等各类文件的数量与占比。



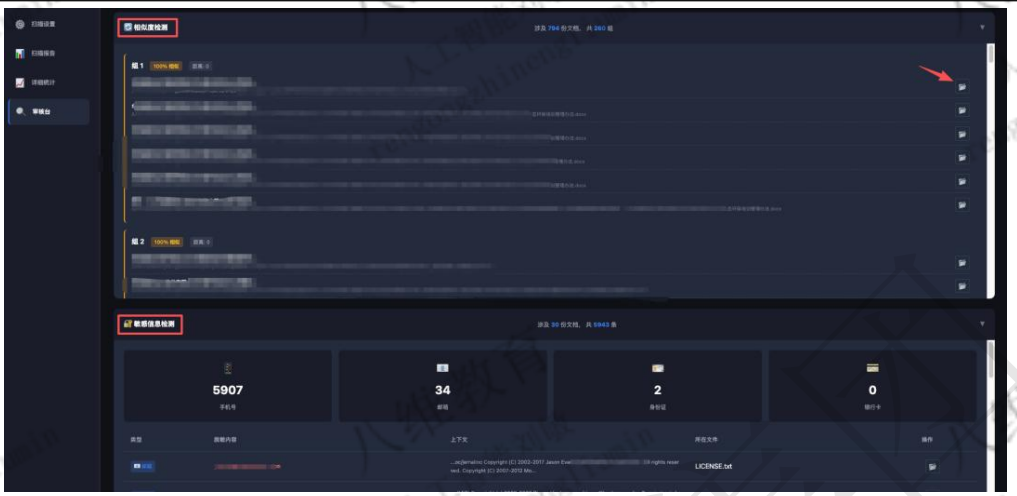
2、**PDF 页面类型识别**：判断 PDF 是文字型、扫描型还是混合型。文字型可以直接提取文本，扫描型需要先做 OCR。核心逻辑是按页判断——每页字符数低于阈值就算扫描页，扫描页占比超过 70%就标记整个文件为扫描型。这是一条启发式，用于分流与估算，不保证严格正确；因此所有阈值可配置，且输出‘待确认’列表。



3、**文档长度分布**：统计所有文档的字符数，输出分位数（P25/P50/P75/P90/P99）和长度区间分布。

4、**重复检测。两层机制**：MD5 用于识别完全相同的文件，SimHash 用于识别高相似度的文档（比如不同版本的同一份文件）。MD5 是精确匹配，SimHash 需要人工确认，所以输出是"待确认的版本冲突列表"。

5、**敏感信息检测**。支持手机号、邮箱、身份证检测，银行卡检测默认关闭（误报率太高）。关键改进是从"只展示统计数字"变成"展示待审核列表"，每条匹配记录都附带上下文。



二、文档分类标签体系

标签	判断依据	推荐处理方式
Clean_Markdown	结构清晰，可直接解析	直接分块入库
Scan_PDF	扫描型 PDF	先 OCR /vlm再分块
Table_Heavy	表格多 / 合并单元格多	表格专用转换
Image_Heavy	图片密集	多模态模型处理
Parse_Failed	解析失败	需人工检查

任务三：将 Skill 集成至智能体工作流与 API

注册与测试 Skill：将开发完成的 Skill 注册到 RAGFlow 的智能体技能库中。编写单元测试，验证该 Skill 能独立运行并返回正确的结构化报告。

创建质检专用工作流：基于 Ragflow 项目中的 Agent 框架，创建一个名为 document_ingestion_workflow 的专用工作流。其核心逻辑是：触发质检 -> 调用 DocumentQualityAssessmentSkill -> 根据分类标签路由到不同的解析器（如扫描型路由至 OCR

	解析器）。 **暴露质检 API 端点：**在 RAGFlow 的 API 服务中，新增一个端点（如 POST /v1/document/quality-inspection）。该端点应能接收一个文件夹路径或文件列表，触发质检 Skill，并以清晰、可读的格式（JSON 及 HTML 简报）返回评估报告，特别是各类“待确认”、“待审核”列表。 **任务四：在真实数据集上进行验证与调优** **功能验证：**使用 IMDR 数据集中的 documents/ 文件夹（约 1700 个文件）作为输入，运行质检 Skill。 **结果分析：** ● 验证统计结果是否符合数据集的整体特征（如扫描型 PDF 占比较高）。 ● 人工抽查“待确认的版本冲突列表”和“待审核的敏感信息列表”，验证检测的准确率与误报率。 ● 审查自动分类标签的合理性。
工时预估	2 人日
产出物	1、**完整的 Skill 源代码**：document_quality_assessment/ 目录下的所有代码文件。 2、**集成后的工作流与 API 代码**：包含新工作流定义和新增 API

	端点的代码变更。 3、**配置文件**：Skill 所有可调参数的配置文件（如 assessment_config.yaml）。 4、**测试脚本与验证报告**：针对 Skill 核心功能的单元测试。 5、**系统演示视频**： ● 展示通过 API 调用文档质检功能。 ● 展示质检报告的核心内容，重点演示如何从报告中定位“扫描型 PDF”、“重复文件”和“敏感信息待审项”。 ● 展示智能体工作流如何根据质检结果，自动将一份 Scan_PDF 标签的文档路由至 OCR 解析流程。
验收标准	**1、功能验收（核心）：** ● **五大功能全覆盖：对测试数据集，Skill 必须完整执行格式统计、PDF 分类、长度分析、重复检测、敏感信息检测，并输出所有要求的列表。** ● **分类准确性：自动分配的文档分类标签，经人工抽样验证，准确率需达到 85%以上。** ● **列表可操作性：“待确认的版本冲突列表”和“待审核的敏感信息列表”中的每一项都必须包含足以让操作员进行判断的关键信息（如文件路径、相似片段、敏感信息上下文）。** **2、集成验收：** **Skill 能通过 API 端点被成功调用，并返回结构化的 JSON 报告。**

	该 Skill 可被成功注册，并能被智能体工作流中的决策节点调用。 **3、代码质量验收：** ● **代码结构清晰，符合 RAGFlow 项目的规范。** ● **所有核心判断逻辑的阈值必须配置化，不硬编码在代码中。** ● **有良好的错误处理机制（如处理损坏的 PDF 文件）。**
备注	1、本工单是技能（Skill）开发能力的专项锻炼，与之前的工单相对独立，可并行或稍后进行。 2、关于 SimHash：此为进阶要求。若时间有限或实现难度过高，可先实现 MD5 精确去重，并将 SimHash 作为扩展项列出实现方案。 3、关于性能：处理 1700 份文档可能耗时较长，在实现时请考虑增加进度反馈和支持中断恢复的能力。