

RAG 项目

Embedding 模型微调 任务工单

八维文化与产业研究院

2025 年 8 月

1 基本信息

工单对应的项目名称	RAG
工单编号	人工智能 NLP-RAG 项目-Embedding 模型微调任务
创建时间	2025 年 8 月 26 日
创建人	王洪荣

2 任务描述

任务描述	虽然通用嵌入模型在大规模网络语料库上预训练，为语义理解提供了良好的起点，但当它们面对小众专业中普遍存在的专业术语、独特实体和特定语义关联时，其性能可能会下降。医学研究、法律判例、专有工程文档，甚至特定的金融工具，常常以通用模型尚未充分掌握的方式使用语言。这种差异，常被称为“语义鸿沟”，可能导致检索结果不理想，即系统未能理解用户意图或无法在您的专业知识库中找到最相关的文档。在专业数据上微调嵌入模型是弥补此鸿沟的一种方法，能大幅提升 RAG 系统检索部分的准确性。 专业化微调的主要目的是调整嵌入空间，使其更准确地反映与目标专业相关的语义相似性与差异。这意味着，包含特定
------	---

专业术语的查询和文档，如果它们在该专业内语义相关，即使其表面形式或通用含义可能有所不同，也会被映射到彼此更接近的向量表示。

为何投入微调？解决语义不匹配问题

设想一个旨在辅助法律专业人员的 RAG 系统。一个通用嵌入模型可能会将“complaint”（诉状/投诉）一词理解为其日常意义上的抱怨。然而，在法律语境中，“complaint”是一种特定类型的 C_LEGAL_DOCUMENT 正式文件，用以启动诉讼。同样，一家软件公司的内部 RAG 系统可能会处理诸如“Project Phoenix”之类的项目代号或内部库名称，这些名称对通用模型来说毫无意义，但在公司内部却具有精确的技术含义。

若不进行微调，检索器可能会遇到困难：

- 误解查询：将通用语义意义赋予专业术语。
- 遗漏相关文档：未能将查询与使用特定专业同义词或相关术语的文档联系起来，这些术语在通用嵌入空间中未得到充分表示。
- 检索不相关文档：过分强调通用相似性，而忽略特定专业差异。

微调使嵌入模型能够学习这些特定专业细节，从而让检索器更准确地“理解”您的内容和用户查询。

一、微调准备：数据很重要

微调的成功在很大程度上取决于专业数据的可用性和质量。您需要一个基础的预训练嵌入模型，例如来自Sentence Transformers库的模型（如all-mpnet-base-v2、multi-qa-MiniLM-L6-cos-v1），或通过API提供的模型，以及一个能反映您专业语言的数据集。

用于微调嵌入模型的常见数据集类型包括：

1. 有监督数据集：这些数据集提供明确的相关性或相似性信号。

- 查询-正向文档对 (query, positive document)：这通常是最有效的数据类型。每对由一个查询（或问题）和一个已知与该查询高度相关的文档片段组成。它们可以来自现有搜索日志、专家标注或常见问题-答案对。
- 句子/文档三元组集 (anchor, positive, negative)：这些数据集由一个锚定文档/句子、一个正向示例（与锚定语义相似）和一个负向示例（与锚定语义不相似）组成。模型学习将锚定和正向示例拉近，同时将锚定和负向示例推开。
- 相关性评分对 (text_1, text_2, score)：带有数字分数（例如，0到1的范围）的文本对，指示其语义相似程度。

2. 无监督/自监督数据集（专业自适应预训练 - DAPT / 任务自适应预训练 - TAPT）：当有标签的有监督数据稀缺时，您仍然可以使用大量原始专业文本来调整模型。

- 专业自适应预训练 (DAPT)：指在目标专业的大规模未标记语料库上继续嵌入模型的预训练过程（例如，掩码语言建模）。这有助于模型掌握特定专业的词汇、语法和共现模式。
- 任务自适应预训练 (TAPT)：类似于DAPT，但未标记语料库更侧重于与您的RAG系统最终将处理的数据类型相似的文本（例如，如果您的RAG用于产品手册的问答，TAPT将使用这些手册）。

另外，通过合成生成训练数据也越来越普遍，例如，使用强大的大型语言模型为给定文档片段生成合理的疑问，或改写现有查询。虽然有益，但合成生成数据的质量需要仔细监督。

二、核心微调策略

1. 对比学习

对比学习是训练句子和文档嵌入模型的一种重要方法。其基本思想是训练模型将语义相似的输入映射到嵌入空间中靠近的点，将不相似的输入映射到远离的点。

为此目的广泛使用的损失函数，特别是对于查询-文档对，是多负样本排序损失 (Multiple Negatives Ranking Loss, MNRL)。给定一个查询 q 和一组文档，包含一个正向（相关）文档 d^+ 和若干个负向（不相关）文档 d_i^- ，该损失函数鼓励 q 和 d^+ 之间的相似度得分高于 q 和任何 d_i^- 之间的得分。

单个查询 q 的损失函数可表示为：

$$L(q, d^+, \{d_i^-\}) = -\log \frac{\exp(\text{相似度}(E(q), E(d^+))/\tau)}{\exp(\text{相似度}(E(q), E(d^+))/\tau) + \sum_i \exp(\text{相似度}(E(q), E(d_i^-))/\tau)}$$

其中：

- $E(\cdot)$ 是嵌入函数（即正在微调的模型）。
- 相似度 $(\cdot, \cdot)$ 是相似度函数，通常是余弦相似度。
- τ 是温度超参数，控制分布的锐度。 τ 值越小，分布越尖锐，使模型任务更具挑战性。

难负样本：负样本的选择很重要。难负样本是指语义上与查询接近（因此较弱的模型容易与正向文档混淆）但实际上不相关的文档。在训练批次中包含这些样本通常能使模型更具辨别能力。

2. 基于适配器的微调

大型嵌入模型的完全微调可能计算成本高昂，并存在“灾难性遗忘”的风险，即模型失去其部分通用语言理解能力。基于适配器的方法提供了一种参数效率更高的替代方案。

LoRA（低秩适应）或传统适配器模块等技术涉及冻结预训练模型的权重，并在其架构中注入少量新的、可训练的参数（即适配器）。在微调过程中，只有这些新参数会被更新。


优势包括：

- **降低计算成本：** 更少的参数意味着更快的训练和更低的内存需求。
- **减轻灾难性遗忘：** 预训练模型的大部分知识得以保留。
- **模块化：** 可以针对不同专业或任务训练不同的适配器，并根据需要“即插即用”，共享同一个基础模型。

3. 完全微调

这涉及使用您的专业数据集更新预训练嵌入模型的所有参数。虽然它有可能实现对新专业的最高适应性，但它也是资源消耗最大的，并且如果微调数据集很小或与原始预训练数据差异很大，则存在最高的灾难性遗忘风险。谨慎的正则化和提前停止通常是必要的。

下图展示了嵌入模型用于特定专业RAG的通用工作流程。



嵌入模型专业化微调的工作流程。通用模型使用专业数据和选定的微调策略进行调整，然后进行评估并整合到RAG系统中。

三、微调介绍

BAAI 开发的 BAAI/bge-base-en-v1.5 是高性能文本嵌入模型，在 MTEB/C-MTEB 等基准测试中表现优异，尤其适合计算资源有限的场景。

1、微调数据集格式与损失函数基础

常用数据集格式包括：

- **正例对：** 一对相关的句子（例如，问题、答案）。
- **三元组：** （锚点、正例、负例）三元组，其中锚点与正例

相似，与负例不相似。

- 带相似度分数的句子对：一对带有相似度分数的句子，该分数表明它们之间的关系。
- 带类别的文本：带有相应类别标签的文本。

2、损失函数：引导训练过程

损失函数在嵌入模型的训练中至关重要。它们通过衡量模型预测与真实标签之间的差异，为模型提供调整权重的信号。不同的损失函数适用于不同的数据集格式：

- **三元组损失** (Triplet Loss)：适用于(锚点，正例，负例)三元组数据，促使模型将相似句子的嵌入向量拉近，相异句子的嵌入向量推远。
- **对比损失** (Contrastive Loss)：适用于正负例句子对，强化“相似句子嵌入接近、相异句子嵌入远离”的特征学习。
- **余弦相似度损失** (Cosine Similarity Loss)：适用于带相似度分数的句子对，引导模型生成的嵌入向量余弦相似度与标注分数一致。
- **套娃损失** (Matryoshka Loss)：专为生成可截断嵌入设计的特殊损失函数，确保嵌入向量具备分层可截断特性。

四、微调实战

参考：<https://zhuanlan.zhihu.com/p/1918237424745714815>

	微调自己领域的 Embedding 模型，需要实现： 数据集生成、运行问答对生成、数据集与模型加载、定义损失函数、定义训练参数、创建评估器、微调前评估模型、微调后评估模型；
工时预估	2 人日
产出物	1、实现步骤，过程问题记录文档或者演示视频； 2、生成的数据集、模型训练过程、微调前后模型评估结果
验收标准	微调后的 Embedding 模型的检索效果比微调前要好，要有数据指标支撑；
备注	