工单2 · 基于PDF文档的问答系统优化

设计 / 研发 / 测试 / 优化 / 部署

交付日期：2026-10-12

完整代码、源资料、实测记录和演示视频分别保存在当前项目目录。所有源PDF、嵌入模型、索引、图谱、图像、测试集与日志均位于本工单目录。本项目运行时不访问其他工单文件。LLM调用本机已有Ollama服务，其环境与模型名称单独记录；主目录无公共数据。

策略baseline：Hit@5=70.0%，MRR@5=0.433，事实关键词覆盖代理=80.0%。 策略dense：Hit@5=80.0%，MRR@5=0.633，事实关键词覆盖代理=82.5%。 策略fulltext：Hit@5=80.0%，MRR@5=0.508，事实关键词覆盖代理=80.0%。 策略hybrid：Hit@5=100.0%，MRR@5=0.825，事实关键词覆盖代理=100.0%。 真实生成10题，完整稳态耗时809.04-9975.72ms；当前样本3秒目标未通过。不包含模型冷启动。

设计：基于PDF文档的问答系统优化

工单编号：人工智能NLP-RAG-基于PDF文档的问答系统优化

工单需求

原工单1已有PDF问答，需优化解析、分块、检索质量，答案准确率目标90%以上，完整响应不超过3秒。

数据与关联

所有源PDF、嵌入模型、索引、图谱、图像、测试集与日志均位于本工单目录。本项目运行时不访问其他工单文件。LLM调用本机已有Ollama服务，其环境与模型名称单独记录；主目录无公共数据。

本项目使用1个PDF、548个物理页。原工单PDF、提取原文与附件哈希在设计目录。项目间复用的是离线复制的代码/数据快照，无运行时共享。

架构

输入问题 -> 会话/术语规范 -> 本项目检索或图谱扩展 -> 证据上下文 -> 本地模型 -> 页码来源/反馈。离线为PDF解析 -> 文本/表格/必要图像摘要 -> 分块 -> BGE/稀疏索引 -> 持久化。

技术选择及边界

保留原问答引擎的本项目独立快照，对页眉清理、重叠分块、发行人实体过滤、直接披露数值的上下文优先和混合检索进行优化。对baseline/dense/fulltext/hybrid作同样本实测；baseline是当前实现的稀疏策略对照，不冒称原工单1所有历史版本。

原PDF只是业务/任务参考资料，不能覆盖用户对目录、环境和部署简化的要求。涉及外部发布或与其他人通信的内容未执行。

研发：基于PDF文档的问答系统优化

实现与源文件

保留原问答引擎的本项目独立快照，对页眉清理、重叠分块、发行人实体过滤、直接披露数值的上下文优先和混合检索进行优化。对baseline/dense/fulltext/hybrid作同样本实测；baseline是当前实现的稀疏策略对照，不冒称原工单1所有历史版本。

研发/app/base.py保存可追溯PDF解析及LLM核心；core.py实现当前项目扩展；server.py/main.py提供本地HTTP和命令行，static/index.html提供网页。build、serve、ask各入口都有本工单注释。

数据结构

每个片段含id、document、pdf_page、kind、text、sha256；pages.json保留完整原页文字和已识别表格；manifest记录解析范围。图谱节点含name/type，关系含source/target/type及chunk_id、文档页码。反馈为JSONL。

实际接口

GET /api/health、/api/documents、/api/graph；POST /api/ask、/api/settings、/api/upload、/api/feedback；/pdf/文档名查看原文。Ask参数question、mode、strategy、session_id。字段和融合配置可通过settings设置。

容错

空问题拒绝、模糊口径澄清、无证据拒答、同名上传保护、非法PDF拒绝；LLM超时回退证据预览并明确标识。扫描空文本页和未尝试表格解析不冒充全部解析成功。

测试：基于PDF文档的问答系统优化

验收用例

10题兴图新科指定问题；保留逐题答案、来源、完整耗时，检索Hit@5/MRR与回答事实覆盖分别统计。工单1已有结果的独立基线见本项目测试目录。

评价口径

Hit@5/MRR是证据页检索指标，事实覆盖是关键词代理；三者均不等于问答准确率。标准答案只在测试脚本中使用，生产问答不读gold.json。完整响应包括生成，无缓存统计另列。

本次实测

策略baseline：Hit@5=70.0%，MRR@5=0.433，事实关键词覆盖代理=80.0%。

策略dense：Hit@5=80.0%，MRR@5=0.633，事实关键词覆盖代理=82.5%。

策略fulltext：Hit@5=80.0%，MRR@5=0.508，事实关键词覆盖代理=80.0%。

策略hybrid：Hit@5=100.0%，MRR@5=0.825，事实关键词覆盖代理=100.0%。

真实生成10题，完整稳态耗时809.04-9975.72ms；当前样本3秒目标未通过。不包含模型冷启动。

自动化日志在测试/自动化测试日志.txt；逐题回答与来源在测试/实测结果.json。

复现

在本目录用指定Python执行“测试/回归测试.py”和“测试/评估.py”。专项微调/性能/LightRAG另有对应脚本与原始日志。

结果限制

单机短时测试不能替代24小时稳定性、生产高并发或真人语音识别。模型评审指标有偏差，RAGAS结果按实际文件读取，失败项单独保留。

优化：基于PDF文档的问答系统优化

本项目优化

语义模型和字符词法模型互补；已披露的军用收入句优先，防止把利润敏感性表当作收入。说明参数变化和对照条件，检索指标不能充当90%问答准确率。

可复现对照

策略baseline：Hit@5=70.0%，MRR@5=0.433，事实关键词覆盖代理=80.0%。

策略dense：Hit@5=80.0%，MRR@5=0.633，事实关键词覆盖代理=82.5%。

策略fulltext：Hit@5=80.0%，MRR@5=0.508，事实关键词覆盖代理=80.0%。

策略hybrid：Hit@5=100.0%，MRR@5=0.825，事实关键词覆盖代理=100.0%。

真实生成10题，完整稳态耗时809.04-9975.72ms；当前样本3秒目标未通过。不包含模型冷启动。

比较保持同问题和同源文档。图谱或检索对照的算法、权重、候选数量及语料范围均需记录，不能用一个代理指标夸大质量。

未达标处理

优先复核单位、页码、实体范围和上下文截断；优化完整证据后复测。未达到阈值或依赖真人/长期负载的要求单独标注，不能因为交付了代码而写成验收合格。

部署：基于PDF文档的问答系统优化

本机三步

1. 双击本目录“一键启动.cmd”。
2. 等待终端显示就绪。
3. 浏览器访问 http://127.0.0.1:8766 。

保持终端打开，Ctrl+C停止。数据与索引已经准备，无需再上传。不同项目使用独立端口，可分别启动。

环境

本次实测Windows、Python3.12，D:/an/envs/rags_/python.exe；各项目自带本地BGE模型目录。所需包在研发/requirements-model.txt；环境版本在部署/环境记录.json。可用- Python参数指定另一环境。Ollama本机服务模型Qwen3.5:4B，地址127.0.0.1:11434；密钥不写文件。

简单维护

备份当前项目研发/data，上传新PDF后后台建库；更新嵌入模型需重建向量。原业务资料不变时无需反复建库。演示视频在部署目录，录制实际网页结果，不伪造语音或模型输出。

特殊要求

本项目无需Docker或独立数据库，优先使用一键本地启动。

指定问题实测摘录

ID 260：报告期内，武汉兴图新科电子股份有限公司来自军用领域的收入分别是多少？

报告期内，武汉兴图新科电子股份有限公司来自军用领域的收入分别为 6,464.51 万元、14,414.16 万元、18,780.67 万元和 4,627.14 万元。［PDF第129页］

完整耗时 9975.72ms。

ID 95：武汉兴图新科电子股份有限公司参与制定了哪个技术标准？

武汉兴图新科电子股份有限公司参与制定的技术标准名称为《某视频技术规范 1.0》。［PDF第95页］、［PDF第160页］、［PDF第181页］、［PDF第182页］

完整耗时 1465.67ms。

ID 33：报告期内，武汉兴图新科电子股份有限公司来自军用领域的收入占主营业务收入的比重分别是多少？

报告期内，武汉兴图新科电子股份有限公司来自军用领域的收入占主营业务收入的比重分别为82.10%、97.31%、94.84%和94.34%。［PDF第129页］［PDF第4页］［PDF第36页］

完整耗时 3656.86ms。

ID 34：根据武汉兴图新科电子股份有限公司招股意向书，电子信息行业的上游涉及哪些企业？

电子信息行业的上游涉及信息系统相关的电子元器件制造企业，以及机箱、机柜等金属壳体制造企业［PDF第152页］。

完整耗时 809.04ms。

ID 957：武汉兴图新科电子股份有限公司在哪个领域已经成为重要供应商？

武汉兴图新科电子股份有限公司在国防军队视频指挥领域已经成为重要供应商。［PDF第154页］［PDF第182页］［PDF第26页］［PDF第27页］［PDF第95页］

完整耗时 2204.02ms。

ID 793：根据武汉兴图新科电子股份有限公司招股意向书，电子信息行业的下游主要包括哪些行业？

根据提供的证据，电子信息行业的下游主要包括军队、政府机关、能源等行业企业。［PDF第152页］

完整耗时 901.69ms。

ID 795：武汉兴图新科电子股份有限公司参与的哪个工程荣获了国家科技进步一等奖？

武汉兴图新科电子股份有限公司参与并独立承担“网络化视频指挥系统”分系统的研发工作，其所属的工程项目为"**某情报、指挥、控制与通信网络一体化工程**"。该工程由某大型研究所牵头承担，于 2014 年 12 月荣获国家科技进步一等奖［PDF第158页］。 需要说明的是，根据招股说明书披露，兴图新科虽然是该工程中网络化视频指挥系统的唯一参与者，但**未能列入获奖名单**［PDF第158页］。

完整耗时 3229.97ms。

ID 543：武汉兴图新科电子股份有限公司注册资本是多少？

武汉兴图新科电子股份有限公司注册资本为 5,520.00 万元［PDF第22页］。

完整耗时 1435.62ms。

ID 531：武汉兴图新科电子股份有限公司法定代表人是谁？

武汉兴图新科电子股份有限公司的法定代表人是程家明。［PDF第52页］［PDF第22页］

完整耗时 1575.71ms。

ID 207：武汉兴图新科电子股份有限公司计划使用本次发行募集资金的多少用于补充流动资金？

武汉兴图新科电子股份有限公司计划使用本次发行募集资金**15,000.00 万元**用于补充流动资金。［PDF第30页］［PDF第484页］［PDF第490页］

完整耗时 2003.54ms。