工单6 · 混合检索与重排

设计 / 研发 / 测试 / 优化 / 部署

交付日期：2026-10-12

完整代码、源资料、实测记录和演示视频分别保存在当前项目目录。所有源PDF、嵌入模型、索引、图谱、图像、测试集与日志均位于本工单目录。本项目运行时不访问其他工单文件。LLM调用本机已有Ollama服务，其环境与模型名称单独记录；主目录无公共数据。

策略baseline：Hit@5=100.0%，MRR@5=0.856，事实关键词覆盖代理=100.0%。 策略dense：Hit@5=100.0%，MRR@5=0.856，事实关键词覆盖代理=100.0%。 策略fulltext：Hit@5=88.9%，MRR@5=0.681，事实关键词覆盖代理=88.9%。 策略hybrid：Hit@5=100.0%，MRR@5=0.764，事实关键词覆盖代理=100.0%。 真实生成18题，完整稳态耗时729.27-2111.00ms；当前样本3秒目标通过。不包含模型冷启动。

设计：混合检索与重排

工单编号：人工智能NLP-RAG-混合检索与重排

工单需求

提供向量召回重排、倒排全文检索及混合策略；支持三种重排、布尔/短语/模糊/多字段、权重和融合配置。

数据与关联

所有源PDF、嵌入模型、索引、图谱、图像、测试集与日志均位于本工单目录。本项目运行时不访问其他工单文件。LLM调用本机已有Ollama服务，其环境与模型名称单独记录；主目录无公共数据。

本项目使用2个PDF、898个物理页。原工单PDF、提取原文与附件哈希在设计目录。项目间复用的是离线复制的代码/数据快照，无运行时共享。

架构

输入问题 -> 会话/术语规范 -> 本项目检索或图谱扩展 -> 证据上下文 -> 本地模型 -> 页码来源/反馈。离线为PDF解析 -> 文本/表格/必要图像摘要 -> 分块 -> BGE/稀疏索引 -> 持久化。

技术选择及边界

BGE语义余弦召回；字符词项倒排索引与BM25全文评分；RRF按weight融合排名。三种重排为TF-IDF分数重排、真实本地LLM序号重排、反馈增益重排；支持body/title/summary字段及AND/OR/NOT、双引号短语、近似词项匹配。

原PDF只是业务/任务参考资料，不能覆盖用户对目录、环境和部署简化的要求。涉及外部发布或与其他人通信的内容未执行。

研发：混合检索与重排

实现与源文件

BGE语义余弦召回；字符词项倒排索引与BM25全文评分；RRF按weight融合排名。三种重排为TF-IDF分数重排、真实本地LLM序号重排、反馈增益重排；支持body/title/summary字段及AND/OR/NOT、双引号短语、近似词项匹配。

研发/app/base.py保存可追溯PDF解析及LLM核心；core.py实现当前项目扩展；server.py/main.py提供本地HTTP和命令行，static/index.html提供网页。build、serve、ask各入口都有本工单注释。

数据结构

每个片段含id、document、pdf_page、kind、text、sha256；pages.json保留完整原页文字和已识别表格；manifest记录解析范围。图谱节点含name/type，关系含source/target/type及chunk_id、文档页码。反馈为JSONL。

实际接口

GET /api/health、/api/documents、/api/graph；POST /api/ask、/api/settings、/api/upload、/api/feedback；/pdf/文档名查看原文。Ask参数question、mode、strategy、session_id。字段和融合配置可通过settings设置。

容错

空问题拒绝、模糊口径澄清、无证据拒答、同名上传保护、非法PDF拒绝；LLM超时回退证据预览并明确标识。扫描空文本页和未尝试表格解析不冒充全部解析成功。

测试：混合检索与重排

验收用例

三策略逐题对照；布尔和短语匹配回归；多轮与反馈入口验证。Hit@5是标注页命中率；工单要求的95%重要事实召回还需用完整相关性标注衡量，不能直接与Hit@5等同。

评价口径

Hit@5/MRR是证据页检索指标，事实覆盖是关键词代理；三者均不等于问答准确率。标准答案只在测试脚本中使用，生产问答不读gold.json。完整响应包括生成，无缓存统计另列。

本次实测

策略baseline：Hit@5=100.0%，MRR@5=0.856，事实关键词覆盖代理=100.0%。

策略dense：Hit@5=100.0%，MRR@5=0.856，事实关键词覆盖代理=100.0%。

策略fulltext：Hit@5=88.9%，MRR@5=0.681，事实关键词覆盖代理=88.9%。

策略hybrid：Hit@5=100.0%，MRR@5=0.764，事实关键词覆盖代理=100.0%。

真实生成18题，完整稳态耗时729.27-2111.00ms；当前样本3秒目标通过。不包含模型冷启动。

自动化日志在测试/自动化测试日志.txt；逐题回答与来源在测试/实测结果.json。

复现

在本目录用指定Python执行“测试/回归测试.py”和“测试/评估.py”。专项微调/性能/LightRAG另有对应脚本与原始日志。

结果限制

单机短时测试不能替代24小时稳定性、生产高并发或真人语音识别。模型评审指标有偏差，RAGAS结果按实际文件读取，失败项单独保留。

第二嵌入模型验证.json


```
{
"model": "bge-m3:567m",
"shape": [
2,
1024
],
"normalized": true,
"similarity": 0.5690687894821167
```

```
}
```

优化：混合检索与重排

本项目优化

字段过滤后排序，保留精确数字与实体；融合权重0到1可调。本地BGE-small与Ollama bge-m3嵌入均有真实验证，BGE-m3验证为1024维单位范数。EMBEDDING_BACKEND=ollama可选择服务嵌入，更换模型必须重建索引，完整检索对照仍使用BGE-small。

可复现对照

策略baseline：Hit@5=100.0%，MRR@5=0.856，事实关键词覆盖代理=100.0%。

策略dense：Hit@5=100.0%，MRR@5=0.856，事实关键词覆盖代理=100.0%。

策略fulltext：Hit@5=88.9%，MRR@5=0.681，事实关键词覆盖代理=88.9%。

策略hybrid：Hit@5=100.0%，MRR@5=0.764，事实关键词覆盖代理=100.0%。

真实生成18题，完整稳态耗时729.27-2111.00ms；当前样本3秒目标通过。不包含模型冷启动。

比较保持同问题和同源文档。图谱或检索对照的算法、权重、候选数量及语料范围均需记录，不能用一个代理指标夸大质量。

未达标处理

优先复核单位、页码、实体范围和上下文截断；优化完整证据后复测。未达到阈值或依赖真人/长期负载的要求单独标注，不能因为交付了代码而写成验收合格。

部署：混合检索与重排

本机三步

1. 双击本目录“一键启动.cmd”。
2. 等待终端显示就绪。
3. 浏览器访问 http://127.0.0.1:8770 。

保持终端打开，Ctrl+C停止。数据与索引已经准备，无需再上传。不同项目使用独立端口，可分别启动。

环境

本次实测Windows、Python3.12，D:/an/envs/rags_/python.exe；各项目自带本地BGE模型目录。所需包在研发/requirements-model.txt；环境版本在部署/环境记录.json。可用- Python参数指定另一环境。Ollama本机服务模型Qwen3.5:4B，地址127.0.0.1:11434；密钥不写文件。

简单维护

备份当前项目研发/data，上传新PDF后后台建库；更新嵌入模型需重建向量。原业务资料不变时无需反复建库。演示视频在部署目录，录制实际网页结果，不伪造语音或模型输出。

特殊要求

本项目无需Docker或独立数据库，优先使用一键本地启动。

指定问题实测摘录

ID 260：报告期内，武汉兴图新科电子股份有限公司来自军用领域的收入分别是多少？

报告期内，公司来自军用领域的收入分别为 6,464.51 万元、14,414.16 万元、18,780.67 万元和 4,627.14 万元 [PDF第129页]。

完整耗时 1722.56ms。

ID 95：武汉兴图新科电子股份有限公司参与制定了哪个技术标准？

武汉兴图新科电子股份有限公司参与制定了全军第一个视频指挥系统技术标准，即《某视频技术规范 1.0》[PDF第27页]。

完整耗时 865.24ms。

ID 33：报告期内，武汉兴图新科电子股份有限公司来自军用领域的收入占主营业务收入的比重分别是多少？

报告期内，公司来自军用领域的收入占主营业务收入比重分别为 82.10%、97.31%、94.84% 和 94.34%，对应年份为 2016 年、2017 年、2018 年和 2019 年 1-6 月。[PDF第129页][PDF第36页]

完整耗时 1940.22ms。

ID 34：根据武汉兴图新科电子股份有限公司招股意向书，电子信息行业的上游涉及哪些企业？

电子信息行业上游涉及信息系统相关电子元器件制造企业和机箱、机柜等金属壳体制造企业 [PDF第152页]。

完整耗时 729.27ms。

ID 957：武汉兴图新科电子股份有限公司在哪个领域已经成为重要供应商？

武汉兴图新科电子股份有限公司在国防军队视频指挥领域已成为重要供应商 [PDF第154页]。

完整耗时 1509.36ms。

ID 793：根据武汉兴图新科电子股份有限公司招股意向书，电子信息行业的下游主要包括哪些行业？

电子信息行业下游主要覆盖军队、政府机关、能源等行业企业 [PDF第152页]。

完整耗时 739.58ms。

ID 795：武汉兴图新科电子股份有限公司参与的哪个工程荣获了国家科技进步一等奖？

兴图新科参与由某大型研究所牵头承担的“某情报、指挥、控制与通信网络一体化工程”（即相当于美军的 C4ISR 系统），该工程于 2014 年 12 月荣获国家科技进步一等奖 [PDF第157页]。

完整耗时 2035.29ms。

ID 543：武汉兴图新科电子股份有限公司注册资本是多少？

武汉兴图新科电子股份有限公司注册资本为 5,520 万元，依据招股说明书［PDF第52页］及［PDF第22页］披露。

完整耗时 1448.15ms。

ID 531：武汉兴图新科电子股份有限公司法定代表人是谁？

武汉兴图新科电子股份有限公司法定代表人为程家明，依据招股说明书披露信息［PDF第52页］。

完整耗时 1390.93ms。

ID 207：武汉兴图新科电子股份有限公司计划使用本次发行募集资金的多少用于补充流动资金？

武汉兴图新科电子股份有限公司计划使用本次发行募集资金 15,000 万元用于补充流动资金［PDF第479页］。

完整耗时 1692.9ms。

ID 1：武汉力源信息技术股份有限公司本次发行股数是多少，占发行后总股本的比例是多少？

武汉力源本次发行股数为 1,670 万股，占发行后总股本比例为 25.04%。[PDF第24页]

完整耗时 1973.39ms。

ID 2：武汉力源信息技术股份有限公司本次募集资金拟投资哪些项目？

武汉力源拟投资仓储及物流中心、研发中心、电子商务平台、扩充产品种类和数量及营运资金［PDF第305页］。

完整耗时 1738.28ms。

ID 3：与武汉力源信息技术股份有限公司存在控制关系的关联方是谁，持股比例和本公司关系是什么？

赵马克，持股 42.35%，系公司控股股东［PDF第158页］。

完整耗时 2111.0ms。

ID 4：与武汉力源信息技术股份有限公司不存在控制关系的关联方企业有哪些？

融冰投资、听音投资、联众聚源、武汉博润、上海博润、力源贸易、普芯达。[PDF第158页]

完整耗时 1771.86ms。

ID 5：武汉力源信息技术股份有限公司组织结构图中，销售部有几个部门构成，其中大客户销售部有几个销售处构成？

销售部由电话及网络销售部、渠道销售部、大客户销售部、国际贸易部 4 个部门构成；大客户销售部下设珠海、深圳、北京、武汉、广州、成都共 6 个销售处。[PDF第39页]

完整耗时 1614.92ms。

ID 6：武汉力源信息技术股份有限公司招股意向书中，从2008年中国IC市场应用结构与增长图中可以看出，增长率最快的是哪个行业？负增长的是哪个行业？

根据 [PDF第72页]，2008 年中国 IC 市场应用结构中，增长率最快的行业是汽车电子（14.0%），负增长的行业是 IC 卡（-2.0%）。

完整耗时 1618.92ms。

ID 15：武汉力源信息技术股份有限公司法定代表人是谁？

武汉力源信息技术股份有限公司法定代表人为赵马克 [PDF第25页]。

完整耗时 1320.96ms。

ID 16：武汉力源信息技术股份有限公司组织结构图中，哪个销售部的销售处最多？有哪些销售处？

大客户销售部下设6个销售处，数量最多。分别为珠海销售处、深圳销售处、北京销售处、武汉销售处、广州销售处、成都销售处 [PDF第39页]。

完整耗时 1411.56ms。