工单9 · GraphRAG优化

设计 / 研发 / 测试 / 优化 / 部署

交付日期：2026-10-12

完整代码、源资料、实测记录和演示视频分别保存在当前项目目录。所有源PDF、嵌入模型、索引、图谱、图像、测试集与日志均位于本工单目录。本项目运行时不访问其他工单文件。LLM调用本机已有Ollama服务，其环境与模型名称单独记录；主目录无公共数据。

策略hybrid：Hit@5=100.0%，MRR@5=0.875，事实关键词覆盖代理=100.0%。 策略graph：Hit@5=100.0%，MRR@5=0.783，事实关键词覆盖代理=100.0%。 策略graph_optimized：Hit@5=100.0%，MRR@5=0.783，事实关键词覆盖代理=100.0%。 真实生成10题，完整稳态耗时843.18-2172.07ms；当前样本3秒目标通过。不包含模型冷启动。

设计：GraphRAG优化

工单编号：人工智能NLP-RAG-GraphRAG优化

工单需求

优化图谱实体关系、检索与生成，并用ContextPrecision/Recall验收，目标0.8/0.9及3秒。

数据与关联

所有源PDF、嵌入模型、索引、图谱、图像、测试集与日志均位于本工单目录。本项目运行时不访问其他工单文件。LLM调用本机已有Ollama服务，其环境与模型名称单独记录；主目录无公共数据。

本项目使用9个PDF、2812个物理页。原工单PDF、提取原文与附件哈希在设计目录。项目间复用的是离线复制的代码/数据快照，无运行时共享。

架构

输入问题 -> 会话/术语规范 -> 本项目检索或图谱扩展 -> 证据上下文 -> 本地模型 -> 页码来源/反馈。离线为PDF解析 -> 文本/表格/必要图像摘要 -> 分块 -> BGE/稀疏索引 -> 持久化。

技术选择及边界

在独立GraphRAG快照上做机构范围过滤、主题锚定和声明完整句选择；RAGAS采用本地Qwen3.5:4B评审，保存原始框架指标、异常与模型版本。若阈值未通过明示差距，不补写合格分数。

原PDF只是业务/任务参考资料，不能覆盖用户对目录、环境和部署简化的要求。涉及外部发布或与其他人通信的内容未执行。

研发：GraphRAG优化

实现与源文件

在独立GraphRAG快照上做机构范围过滤、主题锚定和声明完整句选择；RAGAS采用本地Qwen3.5:4B评审，保存原始框架指标、异常与模型版本。若阈值未通过明示差距，不补写合格分数。

研发/app/base.py保存可追溯PDF解析及LLM核心；core.py实现当前项目扩展；server.py/main.py提供本地HTTP和命令行，static/index.html提供网页。build、serve、ask各入口都有本工单注释。

数据结构

每个片段含id、document、pdf_page、kind、text、sha256；pages.json保留完整原页文字和已识别表格；manifest记录解析范围。图谱节点含name/type，关系含source/target/type及chunk_id、文档页码。反馈为JSONL。

实际接口

GET /api/health、/api/documents、/api/graph；POST /api/ask、/api/settings、/api/upload、/api/feedback；/pdf/文档名查看原文。Ask参数question、mode、strategy、session_id。字段和融合配置可通过settings设置。

容错

空问题拒绝、模糊口径澄清、无证据拒答、同名上传保护、非法PDF拒绝；LLM超时回退证据预览并明确标识。扫描空文本页和未尝试表格解析不冒充全部解析成功。

测试：GraphRAG优化

验收用例

同一10题的hybrid、graph和graph_optimized对照；RAGAS ContextPrecision/Recall为真实模型评审，与关键词代理分开。sample中的xx银行按具名年报复核。

评价口径

Hit@5/MRR是证据页检索指标，事实覆盖是关键词代理；三者均不等于问答准确率。标准答案只在测试脚本中使用，生产问答不读gold.json。完整响应包括生成，无缓存统计另列。

本次实测

策略hybrid：Hit@5=100.0%，MRR@5=0.875，事实关键词覆盖代理=100.0%。

策略graph：Hit@5=100.0%，MRR@5=0.783，事实关键词覆盖代理=100.0%。

策略graph_optimized：Hit@5=100.0%，MRR@5=0.783，事实关键词覆盖代理=100.0%。

真实生成10题，完整稳态耗时843.18-2172.07ms；当前样本3秒目标通过。不包含模型冷启动。

自动化日志在测试/自动化测试日志.txt；逐题回答与来源在测试/实测结果.json。

复现

在本目录用指定Python执行“测试/回归测试.py”和“测试/评估.py”。专项微调/性能/LightRAG另有对应脚本与原始日志。

结果限制

单机短时测试不能替代24小时稳定性、生产高并发或真人语音识别。模型评审指标有偏差，RAGAS结果按实际文件读取，失败项单独保留。

RAGAS指标汇总.json


```
{
"graph_optimized": {
"context_precision": 0.80833333327875,
"context_precision_valid_samples": 10,
"context_recall": 0.925,
"context_recall_valid_samples": 10
},
"hybrid": {
"context_precision": 0.8005555555060371,
```

"context_precision_valid_samples": 10,
"context_recall": 1.0,
"context_recall_valid_samples": 10
},
"graph": {
"context_precision": 0.7616666666217777,
"context_precision_valid_samples": 10,
"context_recall": 1.0,
"context_recall_valid_samples": 10
}
}

优化：GraphRAG优化

本项目优化

改进实体别名、关系来源保真、检索去重和上下文预算；图谱全局摘要不能吞掉具体证据。当前图谱技术为自实现GraphRAG，生产完整实体关系识别仍需扩展。

可复现对照

策略hybrid：Hit@5=100.0%，MRR@5=0.875，事实关键词覆盖代理=100.0%。

策略graph：Hit@5=100.0%，MRR@5=0.783，事实关键词覆盖代理=100.0%。

策略graph_optimized：Hit@5=100.0%，MRR@5=0.783，事实关键词覆盖代理=100.0%。

真实生成10题，完整稳态耗时843.18-2172.07ms；当前样本3秒目标通过。不包含模型冷启动。

比较保持同问题和同源文档。图谱或检索对照的算法、权重、候选数量及语料范围均需记录，不能用一个代理指标夸大质量。

未达标处理

优先复核单位、页码、实体范围和上下文截断；优化完整证据后复测。未达到阈值或依赖真人/长期负载的要求单独标注，不能因为交付了代码而写成验收合格。

部署：GraphRAG优化

本机三步

1. 双击本目录“一键启动.cmd”。
2. 等待终端显示就绪。
3. 浏览器访问 http://127.0.0.1:8773 。

保持终端打开，Ctrl+C停止。数据与索引已经准备，无需再上传。不同项目使用独立端口，可分别启动。

环境

本次实测Windows、Python3.12，D:/an/envs/rags_/python.exe；各项目自带本地BGE模型目录。所需包在研发/requirements-model.txt；环境版本在部署/环境记录.json。可用- Python参数指定另一环境。Ollama本机服务模型Qwen3.5:4B，地址127.0.0.1:11434；密钥不写文件。

简单维护

备份当前项目研发/data，上传新PDF后后台建库；更新嵌入模型需重建向量。原业务资料不变时无需反复建库。演示视频在部署目录，录制实际网页结果，不伪造语音或模型输出。

特殊要求

本项目无需Docker或独立数据库，优先使用一键本地启动。

指定问题实测摘录

ID 101：平安银行2019年董事长致辞中提到盈利增长的关键因素有哪些？

平安银行2019年盈利增长关键因素包括：业务结构优化（零售巩固支柱，对公资金同业提速）；盈利增长趋势形成且风险可控（资产质量夯实）；数据化经营能力提升促进模式创新。[PDF第5页]

完整耗时 1771.04ms。

ID 102：招商银行2019年董事长致辞中探索的创新商业模式有哪些？

招商银行 2019 年探索的创新商业模式包括咖啡零售、出行预订、影票销售等，通过联合合作伙伴共建生态模式 [PDF第5页]。

完整耗时 1299.32ms。

ID 103：平安银行2019年营业收入和净利润分别是多少，同比增速是多少？

平安银行 2019 年实现营业收入 1,379.58 亿元，同比增长 18.2%；净利润 281.95 亿元，同比增长 13.6%。[PDF第5页]

完整耗时 2172.07ms。

ID 104：招商银行2019年归属于股东的净利润及同比增长是多少？

招商银行 2019 年归属于本行股东净利润为 928.67 亿元，同比增长 15.28% [PDF第19页]。

完整耗时 1040.52ms。

ID 105：中国平安2019年归属于母公司股东的净利润及同比增长是多少？

中国平安 2019 年归属于母公司股东的净利润为 1,494.07 亿元，同比增长 39.1% [PDF第7页]。

完整耗时 984.42ms。

ID 106：国泰君安2021年董事长致辞披露的营业收入和归母净利润约是多少？

2021 年国泰君安董事长致辞披露营业收入约 428 亿元，归母净利润约 150 亿元 [PDF第4页]。

完整耗时 965.26ms。

ID 107：平安银行2019年如何通过科技改善小微企业的融资审批和放款效率？

平安银行将小微企业融资审批从传统 30 天缩短到最快 26 秒，放款用时从 3 天减少到最快 10 秒 [PDF第6页]。

完整耗时 2029.13ms。

ID 108：平安银行2019年的零售转型战略在新阶段有哪些着力点？

平安银行 2019 年零售转型战略新阶段的着力点是数字化银行、生态银行、平台银行 [PDF第8页]。

完整耗时 843.18ms。

ID 109：招商银行2019年如何改善资产质量和补充资本？

招商银行通过多措并举落实“两增两控”及房地产贷款调控目标，优化大类资产配置，实现不良额和不良率连续三年“双降”，同时保持资本持续内生，核心一级资本充足率不断提升。[PDF第5页]

完整耗时 1576.91ms。

ID 110：比较平安银行和招商银行2019年董事长致辞中风险管理与数字化创新的共同策略与差异。

平安银行强调数据化经营能力，打造三大“大脑”实现经验向数据驱动转变 [PDF第5页]；招商银行侧重加大数字化投入提升获客、经营和风控能力，并巩固稳健审慎风险文化以完善管理体系 [PDF第6页]。两者均重视数字化转型与风控，但平安侧重智能决策大脑构建，招商侧重生态模式创新与机制保障。

完整耗时 2112.94ms。