工单10 · 金融问答系统Docker部署

设计 / 研发 / 测试 / 优化 / 部署

交付日期：2026-10-12

完整代码、源资料、实测记录和演示视频分别保存在当前项目目录。所有源PDF、嵌入模型、索引、图谱、图像、测试集与日志均位于本工单目录。本项目运行时不访问其他工单文件。LLM调用本机已有Ollama服务，其环境与模型名称单独记录；主目录无公共数据。

策略hybrid：Hit@5=70.0%，MRR@5=0.620，事实关键词覆盖代理=85.0%。 策略graph：Hit@5=70.0%，MRR@5=0.620，事实关键词覆盖代理=85.0%。 策略graph_optimized：Hit@5=70.0%，MRR@5=0.620，事实关键词覆盖代理=85.0%。 真实生成10题，完整稳态耗时794.15-1862.34ms；当前样本3秒目标通过。不包含模型冷启动。

设计：金融问答系统Docker部署

工单编号：人工智能NLP-RAG-金融问答系统Docker部署

工单需求

将金融问答服务以Docker容器在服务器环境成功运行，验证端口、持久化卷和网络。

数据与关联

所有源PDF、嵌入模型、索引、图谱、图像、测试集与日志均位于本工单目录。本项目运行时不访问其他工单文件。LLM调用本机已有Ollama服务，其环境与模型名称单独记录；主目录无公共数据。

本项目使用9个PDF、2812个物理页。原工单PDF、提取原文与附件哈希在设计目录。项目间复用的是离线复制的代码/数据快照，无运行时共享。

架构

输入问题 -> 会话/术语规范 -> 本项目检索或图谱扩展 -> 证据上下文 -> 本地模型 -> 页码来源/反馈。离线为PDF解析 -> 文本/表格/必要图像摘要 -> 分块 -> BGE/稀疏索引 -> 持久化。

技术选择及边界

实际使用WSL Ubuntu的Docker29，构建python:3.11-slim镜像rag-workorder10:local；数据卷只挂载本工单研发/data。初次bridge无法访问Windows仅本机绑定Ollama，改为WSL host网络访问本地模型。

原PDF只是业务/任务参考资料，不能覆盖用户对目录、环境和部署简化的要求。涉及外部发布或与其他人通信的内容未执行。

研发：金融问答系统Docker部署

实现与源文件

实际使用WSL Ubuntu的Docker29，构建python:3.11-slim镜像rag-workorder10:local；数据卷只挂载本工单研发/data。初次bridge无法访问Windows仅本机绑定Ollama，改为WSL host网络访问本地模型。

研发/app/base.py保存可追溯PDF解析及LLM核心；core.py实现当前项目扩展；server.py/main.py提供本地HTTP和命令行，static/index.html提供网页。build、serve、ask各入口都有本工单注释。

数据结构

每个片段含id、document、pdf_page、kind、text、sha256；pages.json保留完整原页文字和已识别表格；manifest记录解析范围。图谱节点含name/type，关系含source/target/type及chunk_id、文档页码。反馈为JSONL。

实际接口

GET /api/health、/api/documents、/api/graph；POST /api/ask、/api/settings、/api/upload、/api/feedback；/pdf/文档名查看原文。Ask参数question、mode、strategy、session_id。字段和融合配置可通过settings设置。

容错

空问题拒绝、模糊口径澄清、无证据拒答、同名上传保护、非法PDF拒绝；LLM超时回退证据预览并明确标识。扫描空文本页和未尝试表格解析不冒充全部解析成功。

测试：金融问答系统Docker部署

验收用例

记录真实镜像、容器状态、HTTP健康/问答、反馈卷持久化和模型网络连通。端口8774。host网络不使用-p映射；停止并重启容器后反馈标记应保留。

评价口径

Hit@5/MRR是证据页检索指标，事实覆盖是关键词代理；三者均不等于问答准确率。标准答案只在测试脚本中使用，生产问答不读gold.json。完整响应包括生成，无缓存统计另列。

本次实测

策略hybrid：Hit@5=70.0%，MRR@5=0.620，事实关键词覆盖代理=85.0%。

策略graph：Hit@5=70.0%，MRR@5=0.620，事实关键词覆盖代理=85.0%。

策略graph_optimized：Hit@5=70.0%，MRR@5=0.620，事实关键词覆盖代理=85.0%。

真实生成10题，完整稳态耗时794.15-1862.34ms；当前样本3秒目标通过。不包含模型冷启动。

自动化日志在测试/自动化测试日志.txt；逐题回答与来源在测试/实测结果.json。

复现

在本目录用指定Python执行“测试/回归测试.py”和“测试/评估.py”。专项微调/性能/LightRAG另有对应脚本与原始日志。

结果限制

单机短时测试不能替代24小时稳定性、生产高并发或真人语音识别。模型评审指标有偏差，RAGAS结果按实际文件读取，失败项单独保留。

优化：金融问答系统Docker部署

本项目优化

轻量镜像不装CUDA/torch，容器使用BM25+TF-IDF并调用本机LLM；Windows版仍可BGE。容器内向量后端与桌面版指标分别说明，不把Windows测试当容器验收。

可复现对照

策略hybrid：Hit@5=70.0%，MRR@5=0.620，事实关键词覆盖代理=85.0%。

策略graph：Hit@5=70.0%，MRR@5=0.620，事实关键词覆盖代理=85.0%。

策略graph_optimized：Hit@5=70.0%，MRR@5=0.620，事实关键词覆盖代理=85.0%。

真实生成10题，完整稳态耗时794.15-1862.34ms；当前样本3秒目标通过。不包含模型冷启动。

比较保持同问题和同源文档。图谱或检索对照的算法、权重、候选数量及语料范围均需记录，不能用一个代理指标夸大质量。

未达标处理

优先复核单位、页码、实体范围和上下文截断；优化完整证据后复测。未达到阈值或依赖真人/长期负载的要求单独标注，不能因为交付了代码而写成验收合格。

部署：金融问答系统Docker部署

本机三步

1. 双击本目录“一键启动.cmd”。
2. 等待终端显示就绪。
3. 浏览器访问 http://127.0.0.1:8774 。

保持终端打开，Ctrl+C停止。数据与索引已经准备，无需再上传。不同项目使用独立端口，可分别启动。

环境

本次实测Windows、Python3.12，D:/an/envs/rags_/python.exe；各项目自带本地BGE模型目录。所需包在研发/requirements-model.txt；环境版本在部署/环境记录.json。可用- Python参数指定另一环境。Ollama本机服务模型Qwen3.5:4B，地址127.0.0.1:11434；密钥不写文件。

简单维护

备份当前项目研发/data，上传新PDF后后台建库；更新嵌入模型需重建向量。原业务资料不变时无需反复建库。演示视频在部署目录，录制实际网页结果，不伪造语音或模型输出。

特殊要求

工单10使用Docker实际部署，详见容器验收记录与容器启动.sh。WSL host网络端口8774，数据卷挂载本工单研发/data。

指定问题实测摘录

ID 101：平安银行2019年董事长致辞中提到盈利增长的关键因素有哪些？

平安银行 2019 年董事长致辞未提及盈利增长关键因素 [PDF第4页]。证据仅显示董事长致辞内容，无相关数据或分析。

完整耗时 1569.85ms。

ID 102：招商银行2019年董事长致辞中探索的创新商业模式有哪些？

招商银行 2019 年董事长致辞中提及的探索创新商业模式为与合作伙伴共建生态的模式创新，并持续积累沉淀创新能力以完善可持续体系 [PDF第6页]。

完整耗时 932.49ms。

ID 103：平安银行2019年营业收入和净利润分别是多少，同比增速是多少？

平安银行2019年营业收入为137,958百万元，净利润为28,195百万元；2018年分别为116,716百万元和24,818百万元。同比增速：营业收入约18.17%，净利润约13.54% [PDF第135页][PDF第221页]。

完整耗时 1743.74ms。

ID 104：招商银行2019年归属于股东的净利润及同比增长是多少？

招商银行 2019 年归属于股东的净利润为 92,867 百万元，同比增长 15.28% [PDF第15页]。

完整耗时 990.96ms。

ID 105：中国平安2019年归属于母公司股东的净利润及同比增长是多少？

中国平安 2019 年归属于母公司股东净利润为 149,407 百万元，同比增长 39.1%。[PDF第10页]

完整耗时 1033.13ms。

ID 106：国泰君安2021年董事长致辞披露的营业收入和归母净利润约是多少？

无法回答。提供的证据中未包含董事长致辞内容，也未披露 2021 年国泰君安合并报表层面的营业收入和归母净利润具体数值，仅提及行业数据及子公司部分收入构成。

完整耗时 1072.83ms。

ID 107：平安银行2019年如何通过科技改善小微企业的融资审批和放款效率？

证据未披露平安银行 2019 年通过科技改善小微企业融资审批和放款效率的具体措施，无法回答。[PDF第6页]、[PDF第7页]、[PDF第26页]、[PDF第28页]

完整耗时 1379.67ms。

ID 108：平安银行2019年的零售转型战略在新阶段有哪些着力点？

平安银行 2019 年零售转型战略新阶段的着力点是数字化银行、生态银行、平台银行 [PDF第8页]。

完整耗时 794.15ms。

ID 109：招商银行2019年如何改善资产质量和补充资本？

招商银行 2019 年处置不良贷款 456.63 亿元，常规核销 254.31 亿元，发行证券面值 8.35 亿元。境内公司房地产贷款余额增加 391.42 亿元，不良率下降 0.73 个百分点。报告未披露补充资本具体举措 [PDF第48页] [PDF第49页]。

完整耗时 1862.34ms。

ID 110：比较平安银行和招商银行2019年董事长致辞中风险管理与数字化创新的共同策略与差异。

平安银行强调数据驱动、融入生态、开放互联以打造智能化零售银行 [PDF第8页]；招商银行侧重用金融科技洞察需求、完善风控体系及优化资产配置 [PDF第6页]。两者均重视数字化与风险，但平安重生态融合，招商重稳健风控与文化传承。

完整耗时 1408.63ms。