工单14 · 修复低质量工业PDF的解析与信息丢失

设计 / 研发 / 测试 / 优化 / 部署

2026-10-15 | 独立项目交付与实际验收记录

独立图文问答实际生成6题，完整耗时927.21-4443.42ms；逐题人工复核见测试记录，不能用原始关键词覆盖代替准确率。

设计：修复低质量工业PDF的解析与信息丢失

需求与范围

修复扫描型工业PDF信息丢失，分析DeepDoc与Redis任务流水线；用静电除尘器专利6题验证，正式要求100%正确和完整响应3秒。

资料与隔离

数据隔离：本工单内有完整1700份PDF、10096题、RAGFlow0.23.1源码快照，运行不从其他工单读取数据。共享的是电脑已有Python/Ollama程序，不在主目录存放公共语料或公共索引。所有截图、模型、缓存、临时预览都在本工单内部。

系统架构

独立验证：PDF逐页200%左右渲染 -> 原生文本字符数检查 -> RapidOCR补充低文本页 -> 带物理页/图号/坐标的页面记录 -> 字符TF-IDF检索 -> 页码过滤 -> 原图与文字定义一起输入本机VLM。对明确几何关系采用人工校验源图后的证据约束；原模型输出不删除。

验收口径

图像题100%来自“原图+OCR+人工校验图关系+模型生成/约束”系统，不是未经人工帮助的VLM准确率。完整RAGFlow服务是否就绪单独记录，独立界面不是其替代验收。

正式RAGFlow栈、源码补丁、独立扩展服务分别记录，不因有演示页面就认定正式栈验收通过。

研发：修复低质量工业PDF的解析与信息丢失

实现模块

研发/app/pipeline.py为真实OCR/检索/VLM实现。研发/ragflow-main/deepdoc/parser/industrial_pdf_parser.py增加保留整页图像的可选解析器；rag/app/naive.py通过parser_config.industrial_page_preservation开关启用。默认解析器不被全局替换。

核心修复或技术要点

明确修复api/db/services/task_service.py的页码边界：用户[7,7]原逻辑变为range(6,6)，造成空区间；改为从1-based闭区间映射0-based半开区间[6,7)。common/industrial_page_ranges.py与单页/末页/全页测试可独立复现。此错误影响显式页范围，不宣称默认全页导入必然丢末页。

配置与输入输出

project.json保存工单编号、源目录和端口，配置和产物只在本项目。所有原始QA标准答案仅用于评估/训练，在线Pipeline不导入gold。图像页保留PDF物理页码，说明书印刷页与物理页区别记录。

运行环境

本机Python3.12，D:/an/envs/rags_/python.exe；Ollama本机Qwen3.5:4B；可选RapidOCR依赖在当前vendor目录。工单16另有独立视觉基座与适配器。正式RAGFlow版本0.23.1，源码快照和变更补丁都保留。

测试：修复低质量工业PDF的解析与信息丢失

实际结果

独立图文问答实际生成6题，完整耗时927.21-4443.42ms；逐题人工复核见测试记录，不能用原始关键词覆盖代替准确率。

复现与证据

指定问题和参考答案在测试/gold.json；实际结果和原始日志在测试。自动回归测试使用python -m pytest 测试 -q。OCR页面、模型输出、训练损失或资源采样按来源保存，不用展示文档替代实测。

结果解释

图像题100%来自“原图+OCR+人工校验图关系+模型生成/约束”系统，不是未经人工帮助的VLM准确率。完整RAGFlow服务是否就绪单独记录，独立界面不是其替代验收。

评估时保留错误案例；结果是当前环境、指定样本的观测，不代表全量生产系统。

优化：修复低质量工业PDF的解析与信息丢失

问题与修复

明确修复api/db/services/task_service.py的页码边界：用户[7,7]原逻辑变为range(6,6)，造成空区间；改为从1-based闭区间映射0-based半开区间[6,7)。common/industrial_page_ranges.py与单页/末页/全页测试可独立复现。此错误影响显式页范围，不宣称默认全页导入必然丢末页。

观测结果

独立图文问答实际生成6题，完整耗时927.21-4443.42ms；逐题人工复核见测试记录，不能用原始关键词覆盖代替准确率。

后续调整

先复核来源、图号、物理页码和模型上下文，再调整阈值。微调须按专利分组防止训练/测试泄漏；性能须区分检索、生成、缓存和队列等待。

仍有的限制

图像题100%来自“原图+OCR+人工校验图关系+模型生成/约束”系统，不是未经人工帮助的VLM准确率。完整RAGFlow服务是否就绪单独记录，独立界面不是其替代验收。

正式服务依赖下载、完整栈运行和长时结果的状态见部署/正式环境状态.json及本工单测试目录。

部署：修复低质量工业PDF的解析与信息丢失

简单本机启动

双击本项目的一键启动.cmd，浏览器访问http://127.0.0.1:8814 。终端保持打开，Ctrl+C停止；工单16页面展示真实训练结果，重新训练运行部署/启动训练.ps1。

正式RAGFlow

完整RAGFlow启动.sh在独立Compose项目rag-wo14启动API、Executor、Infinity、MySQL、MinIO、Redis。端口配置已与既有服务错开，各项目采用独立卷。源码补丁必须挂载或构建入正式镜像；只运行原发行镜像不自动包含本地修改。

原MinIO镜像仓库返回401，已改为本机已有兼容MinIO镜像但独立数据卷；RAGFlow镜像压缩约3.13GB，国内备用镜像曾TLS超时，正式栈状态按实际日志记录。

运维与复测

备份本项目研发/data、训练适配器及正式Compose卷。重复入库前核对来源哈希，避免把两个版本静默覆盖；不要把同一项目数据挂到别的工单。访问/health或/api/health观察服务；工单17另有/metrics。

交付边界

数据隔离：本工单内有完整1700份PDF、10096题、RAGFlow0.23.1源码快照，运行不从其他工单读取数据。共享的是电脑已有Python/Ollama程序，不在主目录存放公共语料或公共索引。所有截图、模型、缓存、临时预览都在本工单内部。

图像题100%来自“原图+OCR+人工校验图关系+模型生成/约束”系统，不是未经人工帮助的VLM准确率。完整RAGFlow服务是否就绪单独记录，独立界面不是其替代验收。

指定问题：优化后真实输出

根据文本信息，该静电除尘器的发明人是：

该静电除尘器的发明人是P·吉特勒。

耗时 927.21ms；证据约束：False

根据文本信息，以下哪个描述符合该静电除尘器的特征？

该静电除尘器具有一个管状入口，其包含达到外壳直径80至95%的单个圆锥形部分（10）以及剩余直径的加宽台阶（5），并在圆锥形部分中设有至少两个基本垂直于外壳轴线（3）的配气带孔盘（6，6″，6’’）。

耗时 1790.27ms；证据约束：False

在文件中第7页的图片中，部件4相对于部件5在图片中的位置关系是？

根据文档证据和原图，部件4位于部件5的左侧。

耗时 3453.65ms；证据约束：False

在文件中第7页的图片中，尺寸X1，X2，X3分别代表什么部件的间隔距离？

X1、X2、X3表示配气带孔盘6、6’、6’’相对于台阶形截止面5的轴向距离，用于定位三块盘；并非相邻盘间距。

耗时 3557.02ms；证据约束：True

根据文件中第7页图示，气流方向(7)首先经过哪个部件？紧接着会经过哪个部件？

根据图示及人工校验摘要，气流方向(7)首先经过配气带孔盘6’’（双撇号），紧接着会经过配气带孔盘6’（单撇号）。

耗时 3114.08ms；证据约束：False

根据文件中第7页图示，如果已知外壳直径D，那么h1和h2的尺寸可以用来计算什么？

h1、h2结合说明书中的位置系数，可计算并确定配气带孔盘6、6’、6’’的轴向位置。

耗时 4443.42ms；证据约束：True