工单16 · 调试与微调专用视觉语言模型

设计 / 研发 / 测试 / 优化 / 部署

2026-10-15 | 独立项目交付与实际验收记录

实际完成2轮LoRA；整体选择题准确率25.0%->37.5%；术语类选择题25.0%->50.0%；图纸题25.0%。损失与权重见真实微调结果和训练日志。

设计：调试与微调专用视觉语言模型

需求与范围

用工业图文QA完成数据转换、LoRA微调、专业评价；至少1个epoch并检查损失下降，术语类指标应有可衡量的提升。

资料与隔离

数据隔离：本工单内有完整1700份PDF、10096题、RAGFlow0.23.1源码快照，运行不从其他工单读取数据。共享的是电脑已有Python/Ollama程序，不在主目录存放公共语料或公共索引。所有截图、模型、缓存、临时预览都在本工单内部。

系统架构

从原10096题按专利文档分组选择训练10篇/验证2篇/测试4篇，每篇选文本及图像题各1条。图像由原PDF题中物理页渲染为PNG；无显式页码时采用首页，因此可能缺失说明书中的关键内容。测试专利不进入训练，工单14/15指定专利也被排除。

验收口径

测试集仅8题，其中术语4题，置信度有限；视觉图像被限制至224×224左右以适配8GB显存，细部识别弱。两轮模型固定训练，没有利用测试集选checkpoint，验证集保留但本次未做超参搜索。

正式RAGFlow栈、源码补丁、独立扩展服务分别记录，不因有演示页面就认定正式栈验收通过。

研发：调试与微调专用视觉语言模型

实现模块

train_lora.py实际加载本工单MinerU2.5-1.2B（Qwen2VL架构），bf16+SDPA+LoRA q_proj/v_proj，rank8、alpha16、lr5e-5、batch1、累积4、梯度检查点，运行2个epoch。适配器保存研发/models/industrial-vlm-lora；PNG和JSONL在data/finetune。finetune_vlm.py另导出image/question/answer与messages格式。

核心修复或技术要点

评价分开报告：整体四选一正确字母比例、group1专业文本题正确率、group2图纸题正确率、原始输出字符级BLEU-1与ROUGE-L。术语类正确率是MCQ代理，不是开放术语生成准确率。选对字母后仍可能生成不相符的文字，报告展示原输出供复核。

配置与输入输出

project.json保存工单编号、源目录和端口，配置和产物只在本项目。所有原始QA标准答案仅用于评估/训练，在线Pipeline不导入gold。图像页保留PDF物理页码，说明书印刷页与物理页区别记录。

运行环境

本机Python3.12，D:/an/envs/rags_/python.exe；Ollama本机Qwen3.5:4B；可选RapidOCR依赖在当前vendor目录。工单16另有独立视觉基座与适配器。正式RAGFlow版本0.23.1，源码快照和变更补丁都保留。

测试：调试与微调专用视觉语言模型

实际结果

实际完成2轮LoRA；整体选择题准确率25.0%->37.5%；术语类选择题25.0%->50.0%；图纸题25.0%。损失与权重见真实微调结果和训练日志。

复现与证据

指定问题和参考答案在测试/gold.json；实际结果和原始日志在测试。自动回归测试使用python -m pytest 测试 -q。OCR页面、模型输出、训练损失或资源采样按来源保存，不用展示文档替代实测。

结果解释

测试集仅8题，其中术语4题，置信度有限；视觉图像被限制至224×224左右以适配8GB显存，细部识别弱。两轮模型固定训练，没有利用测试集选checkpoint，验证集保留但本次未做超参搜索。

评估时保留错误案例；结果是当前环境、指定样本的观测，不代表全量生产系统。

优化：调试与微调专用视觉语言模型

问题与修复

评价分开报告：整体四选一正确字母比例、group1专业文本题正确率、group2图纸题正确率、原始输出字符级BLEU-1与ROUGE-L。术语类正确率是MCQ代理，不是开放术语生成准确率。选对字母后仍可能生成不相符的文字，报告展示原输出供复核。

观测结果

实际完成2轮LoRA；整体选择题准确率25.0%->37.5%；术语类选择题25.0%->50.0%；图纸题25.0%。损失与权重见真实微调结果和训练日志。

后续调整

先复核来源、图号、物理页码和模型上下文，再调整阈值。微调须按专利分组防止训练/测试泄漏；性能须区分检索、生成、缓存和队列等待。

仍有的限制

测试集仅8题，其中术语4题，置信度有限；视觉图像被限制至224×224左右以适配8GB显存，细部识别弱。两轮模型固定训练，没有利用测试集选checkpoint，验证集保留但本次未做超参搜索。

正式服务依赖下载、完整栈运行和长时结果的状态见部署/正式环境状态.json及本工单测试目录。

部署：调试与微调专用视觉语言模型

简单本机启动

双击本项目的一键启动.cmd，浏览器访问http://127.0.0.1:8816 。终端保持打开，Ctrl+C停止；工单16页面展示真实训练结果，重新训练运行部署/启动训练.ps1。

正式RAGFlow

完整RAGFlow启动.sh在独立Compose项目rag-wo16启动API、Executor、Infinity、MySQL、MinIO、Redis。端口配置已与既有服务错开，各项目采用独立卷。源码补丁必须挂载或构建入正式镜像；只运行原发行镜像不自动包含本地修改。

原MinIO镜像仓库返回401，已改为本机已有兼容MinIO镜像但独立数据卷；RAGFlow镜像压缩约3.13GB，国内备用镜像曾TLS超时，正式栈状态按实际日志记录。

运维与复测

备份本项目研发/data、训练适配器及正式Compose卷。重复入库前核对来源哈希，避免把两个版本静默覆盖；不要把同一项目数据挂到别的工单。访问/health或/api/health观察服务；工单17另有/metrics。

交付边界

数据隔离：本工单内有完整1700份PDF、10096题、RAGFlow0.23.1源码快照，运行不从其他工单读取数据。共享的是电脑已有Python/Ollama程序，不在主目录存放公共语料或公共索引。所有截图、模型、缓存、临时预览都在本工单内部。

测试集仅8题，其中术语4题，置信度有限；视觉图像被限制至224×224左右以适配8GB显存，细部识别弱。两轮模型固定训练，没有利用测试集选checkpoint，验证集保留但本次未做超参搜索。