工单17 · 解决API服务并发瓶颈与资源泄漏

设计 / 研发 / 测试 / 优化 / 部署

2026-10-15 | 独立项目交付与实际验收记录

独立真实检索API的JMeter结果：A：599.7秒，55004请求，错误0，检索P95=15ms；B：599.7秒，14270请求，错误197，检索P95=8ms；A-after：599.8秒，55613请求，错误2，检索P95=14ms；B-after：599.7秒，14383请求，错误0，检索P95=9ms；A-final：599.7秒，56397请求，错误0，检索P95=9ms；优化后12小时观察状态：running；该观察为独立API，正式RAGFlow栈另列。

设计：解决API服务并发瓶颈与资源泄漏

需求与范围

正式要求完整RAGFlow API+TaskExecutor+向量库+Redis；JMeter场景A20并发10分钟P95≤3秒、场景B5问答+5上传解析10分钟P95≤5秒、12小时RSS增长≤20%，并提供性能分析和监控。

资料与隔离

数据隔离：本工单内有完整1700份PDF、10096题、RAGFlow0.23.1源码快照，运行不从其他工单读取数据。共享的是电脑已有Python/Ollama程序，不在主目录存放公共语料或公共索引。所有截图、模型、缓存、临时预览都在本工单内部。

系统架构

独立扩展实测：进程内Pipeline单例；4个活跃请求、32个等待容量；128项TTL缓存；解析队列容量16、后台消费；健康与Prometheus端点。真实检索证据来自本工单OCR结果，早期返回模拟字符串的烟测已明确归档，不能用于最终性能结论。

验收口径

JMeter当前接口是独立真实检索/缓存扩展；不含每请求LLM生成，不是完整RAGFlow聊天接口的3秒证明。场景B允许有明确429背压，不能将其写成零失败。正式Redis队列/容器/GPU监控需正式栈就绪后重跑。

正式RAGFlow栈、源码补丁、独立扩展服务分别记录，不因有演示页面就认定正式栈验收通过。

研发：解决API服务并发瓶颈与资源泄漏

实现模块

app/resources.py为容量与TTL缓存；service.py提供真实证据检索和可选LLM生成、PDF上传与解析队列。正式RAGFlow common/bounded_chat.py对流式响应完整生命周期持有信号量，api/apps/sdk/session.py对指定OpenAI兼容端点接入；任务执行器复用有界TOC线程池，使用asyncio.wrap_future异步等待，退出时关闭池。

核心修复或技术要点

源码中无证据证明每次聊天都会把DeepDoc/VLM加载到GPU，不能将工单推测当成实测根因。确认的是TOC线程池没有明确关闭的生命周期风险；独立API中缓存、任务表和队列均有容量界限。py-spy实际采样输出API热点.svg；12小时RSS观测启动后持续写状态，未到时不写合格。

配置与输入输出

project.json保存工单编号、源目录和端口，配置和产物只在本项目。所有原始QA标准答案仅用于评估/训练，在线Pipeline不导入gold。图像页保留PDF物理页码，说明书印刷页与物理页区别记录。

运行环境

本机Python3.12，D:/an/envs/rags_/python.exe；Ollama本机Qwen3.5:4B；可选RapidOCR依赖在当前vendor目录。工单16另有独立视觉基座与适配器。正式RAGFlow版本0.23.1，源码快照和变更补丁都保留。

测试：解决API服务并发瓶颈与资源泄漏

实际结果

独立真实检索API的JMeter结果：A：599.7秒，55004请求，错误0，检索P95=15ms；B：599.7秒，14270请求，错误197，检索P95=8ms；A-after：599.8秒，55613请求，错误2，检索P95=14ms；B-after：599.7秒，14383请求，错误0，检索P95=9ms；A-final：599.7秒，56397请求，错误0，检索P95=9ms；优化后12小时观察状态：running；该观察为独立API，正式RAGFlow栈另列。

复现与证据

指定问题和参考答案在测试/gold.json；实际结果和原始日志在测试。自动回归测试使用python -m pytest 测试 -q。OCR页面、模型输出、训练损失或资源采样按来源保存，不用展示文档替代实测。

结果解释

JMeter当前接口是独立真实检索/缓存扩展；不含每请求LLM生成，不是完整RAGFlow聊天接口的3秒证明。场景B允许有明确429背压，不能将其写成零失败。正式Redis队列/容器/GPU监控需正式栈就绪后重跑。

评估时保留错误案例；结果是当前环境、指定样本的观测，不代表全量生产系统。

优化：解决API服务并发瓶颈与资源泄漏

问题与修复

源码中无证据证明每次聊天都会把DeepDoc/VLM加载到GPU，不能将工单推测当成实测根因。确认的是TOC线程池没有明确关闭的生命周期风险；独立API中缓存、任务表和队列均有容量界限。py-spy实际采样输出API热点.svg；12小时RSS观测启动后持续写状态，未到时不写合格。

观测结果

独立真实检索API的JMeter结果：A：599.7秒，55004请求，错误0，检索P95=15ms；B：599.7秒，14270请求，错误197，检索P95=8ms；A-after：599.8秒，55613请求，错误2，检索P95=14ms；B-after：599.7秒，14383请求，错误0，检索P95=9ms；A-final：599.7秒，56397请求，错误0，检索P95=9ms；优化后12小时观察状态：running；该观察为独立API，正式RAGFlow栈另列。

后续调整

先复核来源、图号、物理页码和模型上下文，再调整阈值。微调须按专利分组防止训练/测试泄漏；性能须区分检索、生成、缓存和队列等待。

仍有的限制

JMeter当前接口是独立真实检索/缓存扩展；不含每请求LLM生成，不是完整RAGFlow聊天接口的3秒证明。场景B允许有明确429背压，不能将其写成零失败。正式Redis队列/容器/GPU监控需正式栈就绪后重跑。

正式服务依赖下载、完整栈运行和长时结果的状态见部署/正式环境状态.json及本工单测试目录。

部署：解决API服务并发瓶颈与资源泄漏

简单本机启动

双击本项目的一键启动.cmd，浏览器访问http://127.0.0.1:8817 。终端保持打开，Ctrl+C停止；工单16页面展示真实训练结果，重新训练运行部署/启动训练.ps1。

正式RAGFlow

完整RAGFlow启动.sh在独立Compose项目rag-wo17启动API、Executor、Infinity、MySQL、MinIO、Redis。端口配置已与既有服务错开，各项目采用独立卷。源码补丁必须挂载或构建入正式镜像；只运行原发行镜像不自动包含本地修改。

原MinIO镜像仓库返回401，已改为本机已有兼容MinIO镜像但独立数据卷；RAGFlow镜像压缩约3.13GB，国内备用镜像曾TLS超时，正式栈状态按实际日志记录。

运维与复测

备份本项目研发/data、训练适配器及正式Compose卷。重复入库前核对来源哈希，避免把两个版本静默覆盖；不要把同一项目数据挂到别的工单。访问/health或/api/health观察服务；工单17另有/metrics。

交付边界

数据隔离：本工单内有完整1700份PDF、10096题、RAGFlow0.23.1源码快照，运行不从其他工单读取数据。共享的是电脑已有Python/Ollama程序，不在主目录存放公共语料或公共索引。所有截图、模型、缓存、临时预览都在本工单内部。

JMeter当前接口是独立真实检索/缓存扩展；不含每请求LLM生成，不是完整RAGFlow聊天接口的3秒证明。场景B允许有明确429背压，不能将其写成零失败。正式Redis队列/容器/GPU监控需正式栈就绪后重跑。