工单18 ·
实现文档质量评估Skill并集成至智能体工作流

设计 / 研发 / 测试 / 优化 / 部署

2026-10-15 | 独立项目交付与实际验收记录

全库1700份：Scan_PDF 622，Text_PDF 333，Mixed_PDF 745；MD5重复组0、SimHash待确认3、内嵌文本敏感待审0。首次全量耗时约64秒，缓存复测约4秒。

设计：实现文档质量评估Skill并集成至智能体工作流

需求与范围

实现DocumentQualityAssessmentSkill，包含格式统计、PDF分类、长度、MD5/SimHash、敏感信息；API和智能体工作流集成；对1700份文档验证，分类抽样目标85%以上。

资料与隔离

数据隔离：本工单内有完整1700份PDF、10096题、RAGFlow0.23.1源码快照，运行不从其他工单读取数据。共享的是电脑已有Python/Ollama程序，不在主目录存放公共语料或公共索引。所有截图、模型、缓存、临时预览都在本工单内部。

系统架构

独立Skill -> 配置读取 -> 逐文件MD5/SHA256 -> 全页字符数与扫描页比例 -> 标签/分流 -> 文本长度与分位数 -> 精确及近重复 -> 敏感信息待审 -> JSON/HTML报告。按文件内容+配置+文件名缓存，进度每50份保存，可中断续跑。

验收口径

Scan_PDF阈值是低字符页占比>70%；Text_PDF允许少数附图页；其余Mixed。人工查看9份分层样本全页，9/9符合本项目分流定义，但不能推断全库准确率100%。近重复只提示人工确认，不自动删除；手机号/邮箱/有效身份证检测，银行卡默认关闭。

正式RAGFlow栈、源码补丁、独立扩展服务分别记录，不因有演示页面就认定正式栈验收通过。

研发：实现文档质量评估Skill并集成至智能体工作流

实现模块

研发/document_quality_assessment包含SKILL.md、assessment.py和assessment_config.yaml。六个核心测试通过，Skill校验通过。本机/v1/document/quality-inspection为实际可调用API；app/workflow.py有注册表和路由。正式RAGFlow新增quality_app蓝图（/v1/quality/inspection）和DocumentQualityAssessment/DocumentIngestionRouter组件，由现有动态发现机制注册。

核心修复或技术要点

全量只分析内嵌文本，扫描图像中的敏感信息尚未全库OCR复检。实测API已经将CN100342976C.pdf路由至OCR并真实提取8页4959字符。正式Agent模板document_ingestion_workflow.json依次质检、按标签解析、返回结果；可配置每次解析文件数，避免一次启动1700份OCR。

配置与输入输出

project.json保存工单编号、源目录和端口，配置和产物只在本项目。所有原始QA标准答案仅用于评估/训练，在线Pipeline不导入gold。图像页保留PDF物理页码，说明书印刷页与物理页区别记录。

运行环境

本机Python3.12，D:/an/envs/rags_/python.exe；Ollama本机Qwen3.5:4B；可选RapidOCR依赖在当前vendor目录。工单16另有独立视觉基座与适配器。正式RAGFlow版本0.23.1，源码快照和变更补丁都保留。

测试：实现文档质量评估Skill并集成至智能体工作流

实际结果

全库1700份：Scan_PDF 622，Text_PDF 333，Mixed_PDF 745；MD5重复组0、SimHash待确认3、内嵌文本敏感待审0。首次全量耗时约64秒，缓存复测约4秒。

复现与证据

指定问题和参考答案在测试/gold.json；实际结果和原始日志在测试。自动回归测试使用python -m pytest 测试 -q。OCR页面、模型输出、训练损失或资源采样按来源保存，不用展示文档替代实测。

结果解释

Scan_PDF阈值是低字符页占比>70%；Text_PDF允许少数附图页；其余Mixed。人工查看9份分层样本全页，9/9符合本项目分流定义，但不能推断全库准确率100%。近重复只提示人工确认，不自动删除；手机号/邮箱/有效身份证检测，银行卡默认关闭。

评估时保留错误案例；结果是当前环境、指定样本的观测，不代表全量生产系统。

优化：实现文档质量评估Skill并集成至智能体工作流

问题与修复

全量只分析内嵌文本，扫描图像中的敏感信息尚未全库OCR复检。实测API已经将CN100342976C.pdf路由至OCR并真实提取8页4959字符。正式Agent模板document_ingestion_workflow.json依次质检、按标签解析、返回结果；可配置每次解析文件数，避免一次启动1700份OCR。

观测结果

全库1700份：Scan_PDF 622，Text_PDF 333，Mixed_PDF 745；MD5重复组0、SimHash待确认3、内嵌文本敏感待审0。首次全量耗时约64秒，缓存复测约4秒。

后续调整

先复核来源、图号、物理页码和模型上下文，再调整阈值。微调须按专利分组防止训练/测试泄漏；性能须区分检索、生成、缓存和队列等待。

仍有的限制

Scan_PDF阈值是低字符页占比>70%；Text_PDF允许少数附图页；其余Mixed。人工查看9份分层样本全页，9/9符合本项目分流定义，但不能推断全库准确率100%。近重复只提示人工确认，不自动删除；手机号/邮箱/有效身份证检测，银行卡默认关闭。

正式服务依赖下载、完整栈运行和长时结果的状态见部署/正式环境状态.json及本工单测试目录。

部署：实现文档质量评估Skill并集成至智能体工作流

简单本机启动

双击本项目的一键启动.cmd，浏览器访问http://127.0.0.1:8818 。终端保持打开，Ctrl+C停止；工单16页面展示真实训练结果，重新训练运行部署/启动训练.ps1。

正式RAGFlow

完整RAGFlow启动.sh在独立Compose项目rag-wo18启动API、Executor、Infinity、MySQL、MinIO、Redis。端口配置已与既有服务错开，各项目采用独立卷。源码补丁必须挂载或构建入正式镜像；只运行原发行镜像不自动包含本地修改。

原MinIO镜像仓库返回401，已改为本机已有兼容MinIO镜像但独立数据卷；RAGFlow镜像压缩约3.13GB，国内备用镜像曾TLS超时，正式栈状态按实际日志记录。

运维与复测

备份本项目研发/data、训练适配器及正式Compose卷。重复入库前核对来源哈希，避免把两个版本静默覆盖；不要把同一项目数据挂到别的工单。访问/health或/api/health观察服务；工单17另有/metrics。

交付边界

数据隔离：本工单内有完整1700份PDF、10096题、RAGFlow0.23.1源码快照，运行不从其他工单读取数据。共享的是电脑已有Python/Ollama程序，不在主目录存放公共语料或公共索引。所有截图、模型、缓存、临时预览都在本工单内部。

Scan_PDF阈值是低字符页占比>70%；Text_PDF允许少数附图页；其余Mixed。人工查看9份分层样本全页，9/9符合本项目分流定义，但不能推断全库准确率100%。近重复只提示人工确认，不自动删除；手机号/邮箱/有效身份证检测，银行卡默认关闭。